

# KAN -

# *KOLMOGOROV-ARNOLD NETWORKS*

---

SIS-421



# Introducción

Las Kolmogorov-Arnold Networks (KAN) son una nueva arquitectura de redes neuronales propuesta por científicos del MIT en abril de 2024. Representan una alternativa revolucionaria a las redes neuronales tradicionales (MLPs), basándose en un teorema matemático de 1957.

## **La diferencia fundamental:**

MLPs tradicionales: Usan funciones de activación fijas (ReLU, sigmoid) en las neuronas  
KAN: Usan funciones aprendibles (B-splines) en las conexiones

## **Ventajas principales:**

Más precisas con menos parámetros

Interpretables (se puede visualizar qué aprende)

Ideales para problemas científicos y datos tabulares

## **KAN: Kolmogorov–Arnold Networks**

Ziming Liu<sup>1,4\*</sup> Yixuan Wang<sup>2</sup> Sachin Vaidya<sup>1</sup> Fabian Ruehle<sup>3,4</sup>  
James Halverson<sup>3,4</sup> Marin Soljačić<sup>1,4</sup> Thomas Y. Hou<sup>2</sup> Max Tegmark<sup>1,4</sup>

<sup>1</sup> Massachusetts Institute of Technology

<sup>2</sup> California Institute of Technology

<sup>3</sup> Northeastern University

<sup>4</sup> The NSF Institute for Artificial Intelligence and Fundamental Interactions

# ¿Qué es KAN?

Las KAN son un tipo de red neuronal artificial que utiliza el Teorema de Representación de Kolmogorov-Arnold como base arquitectónica.

Concepto	MLP (red tradicional)	KAN (Kolmogorov–Arnold Network)
Qué se entrena	<b>Pesos (valores numéricos)</b> que conectan neuronas	<b>Funciones matemáticas</b> entre neuronas
Qué usa entre capas	Multiplicaciones y sumas	<b>Funciones suaves (splines)</b> que se ajustan a los datos
Cómo aprende	Cambia los pesos para mejorar	Ajusta la forma de las funciones para mejorar
Ventaja	Fácil de implementar	Más <b>explicable y precisa con menos parámetros</b>

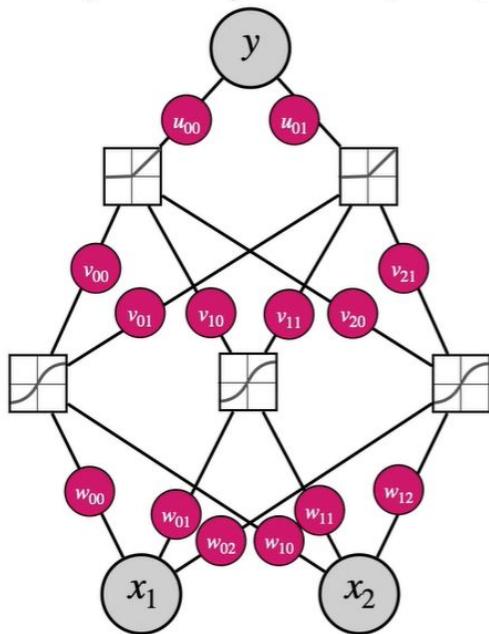
# Ventajas y comparación con MLPs

Las KAN son un tipo de red neuronal artificial que utiliza el Teorema de Representación de Kolmogorov-Arnold como base arquitectónica.

Aspecto	MLPs (tradicionales)	KANs (Kolmogorov-Arnold)
Activaciones	Fijas en nodos (ej. ReLU rígida)	Aprendibles en aristas (splines flexibles)
Precisión	Buena, pero necesita más datos y params	Más precisa con menos params (hasta 96% accuracy en pruebas)
Interpretabilidad	Caja negra (difícil de entender)	Transparente: visualizas funciones como gráficos
Eficiencia	Más memoria y sobreajuste en dims altas	Menos params, mejor generalización (ideal para ciencia)

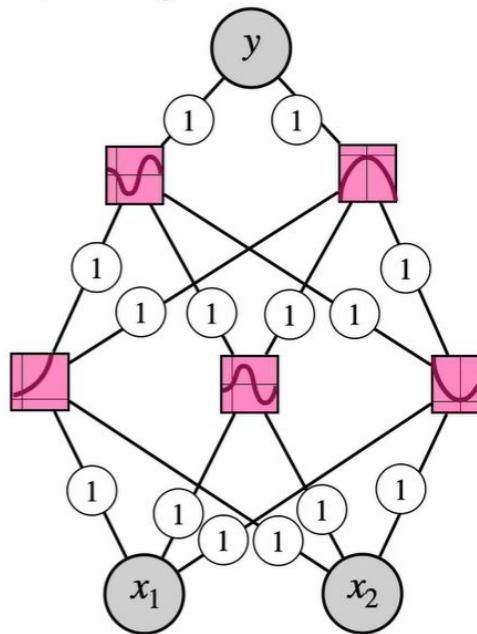
# Arquitectura KAN

**MLP** (Multi-Layer Perceptron)



Fixed activation functions  
Train weights

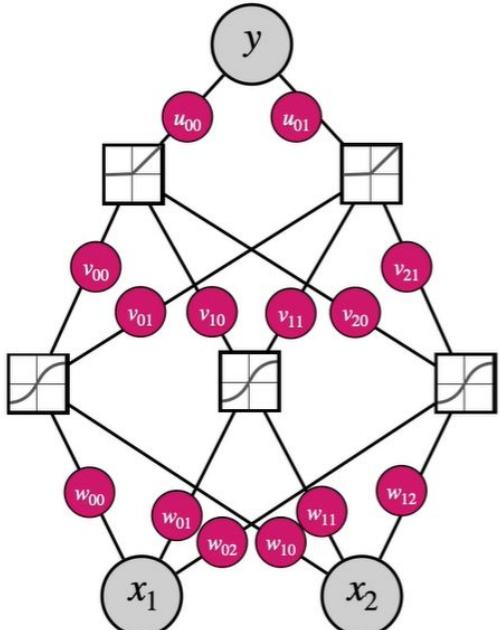
**KAN** (Kolmogorov-Arnold Network)



Fixed weights  
Train activation functions

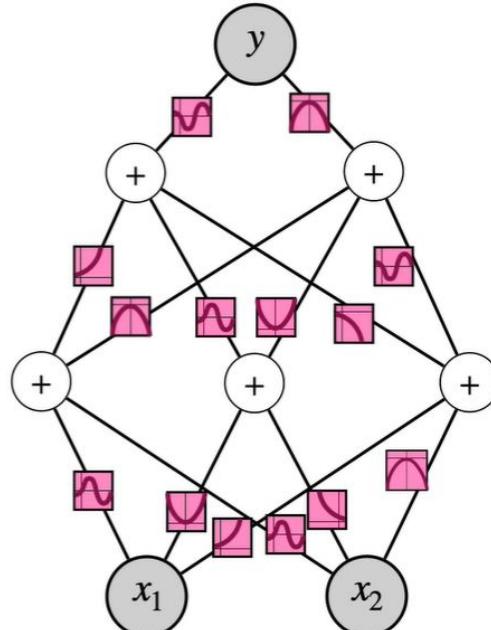
# Arquitectura KAN

MLP (Multi-Layer Perceptron)



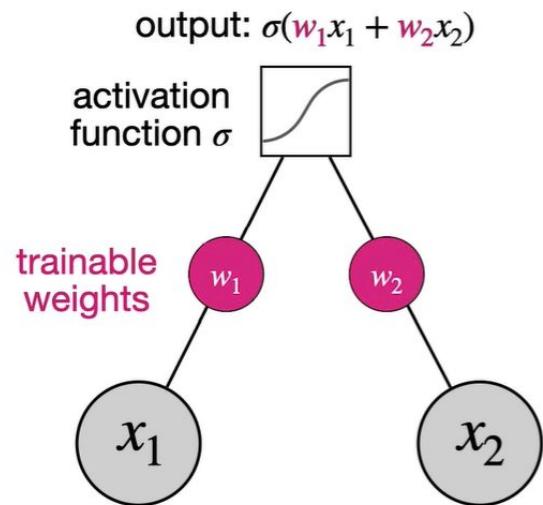
Fixed activation functions  
Train weights

KAN (Kolmogorov-Arnold Network)

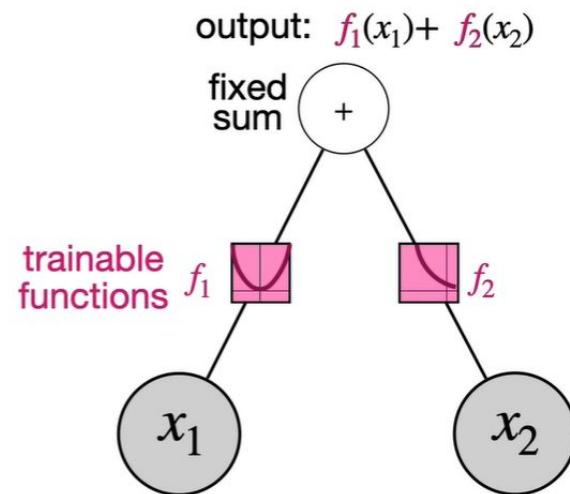


Fixed weights  
Train activation functions

## MLP (Multi-Layer Perceptron)

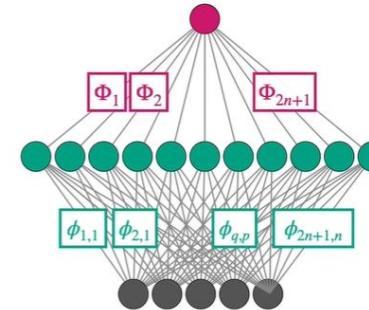


## KAN (Kolmogorov-Arnold Network)

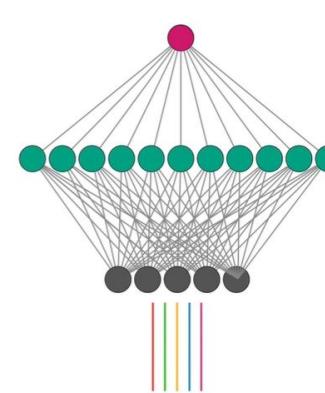


# Teorema de Kolmogorov-Arnold

$$f(x_1, x_2, \dots, x_n) = \sum_{q=1}^{2n+1} \Phi_q \left( \sum_{p=1}^n \phi_{q,p}(x_p) \right)$$



$$f(x_1, x_2, \dots, x_n) = \sum_{q=1}^{2n+1} \Phi_q \left( \sum_{p=1}^n \phi_{q,p}(x_p) \right)$$



El teorema establece que: **Cualquier función continua multivariable** puede descomponerse en una **suma de funciones continuas de una sola variable** (univariantes).

# KAN en la actualidad (2024-2025)

Fueron presentadas por investigadores del MIT en 2024, y hoy se están usando en:

**Investigación científica:** para modelar ecuaciones físicas o químicas difíciles.

**Medicina:** en bioinformática para entender relaciones entre genes y enfermedades.

**Física y dinámica de fluidos:** simular movimientos del aire, agua o calor.

**Modelos explicables de IA (Explainable AI):** porque las funciones que aprenden se pueden visualizar.

En resumen: aún están en fase experimental, pero ya muestran resultados mejores que los MLP tradicionales en varios campos.



# KAN en el futuro

En los próximos años se espera que las KAN:

Reemplacen parcialmente a los MLP y Transformers en tareas donde la explicabilidad sea importante.

Se integren con redes de física (PINNs), modelos de energía, o robótica.

Ayuden a crear IA más eficientes, interpretables y seguras.

Se usen en educación y ciencia para enseñar cómo la IA entiende relaciones matemáticas.